

Escuela Politécnica Nacional

Métodos Numéricos

Nombre: Erick Cuichan

Curso: GR1CC

Tema: Costos relacionados a los modelos de lenguaje

¿Qué es inferencia y entrenamiento?

El **entrenamiento** es la etapa en la que un modelo de lenguaje aprende a partir de grandes cantidades de datos. Durante este proceso, ajusta sus parámetros internos y requiere una gran cantidad de recursos computacionales, como GPUs o TPUs, además de un alto consumo energético.

La **inferencia** ocurre cuando el modelo ya entrenado se utiliza para responder preguntas, generar texto o realizar tareas. En esta fase el modelo no aprende, sino que aplica lo que ya conoce para producir una respuesta.

Palabras clave

- **Entrenamiento = Aprender**
- **Inferencia = Usar lo aprendido**

Tabla resumen de modelos de lenguaje comerciales

Modelo	GPU o acelerador utilizado	Costo del hardware	Tiempo de entrenamiento	Consumo energético en entrenamiento	Consumo energético en inferencia
GPT-4 — OpenAI	GPUs NVIDIA A100 y H100	Se estima que se usaron unas 25 000 GPUs A100, con un costo aproximado de \$700 millones solo en hardware.	No divulgado; su entrenamiento principal finalizó en agosto de 2022	No divulgado. Debido a su escala, habría requerido un consumo muy alto durante el entrenamiento.	Menor que el entrenamiento por consulta individual, pero elevado a gran escala por la cantidad de usuarios.
Claude Opus 4 / Sonnet 4 — Anthropic	Estimación similar a A100 o H100	No divulgado oficialmente, pero se calcula que el gasto estuvo	No divulgado. Probablemente varios meses , incluyendo	No divulgado oficialmente.	No divulgado; depende del tamaño del modelo y del volumen de

Modelo	GPU o acelerador utilizado	Costo del hardware	Tiempo de entrenamiento	Consumo energético en entrenamiento	Consumo energético en inferencia
		en decenas de millones de dólares.	preentrenamiento y ajuste posterior.		consultas atendidas.
Gemini 2.5 Pro — Google	TPUs desarrolladas por Google v4 o v5	No divulgado oficialmente	No divulgado oficialmente. Se estima que requirió meses de entrenamiento.	No divulgado. Google no publica el consumo total en watts.	Google enfatiza eficiencia en sus modelos, pero no reporta watts exactos de inferencia.
Llama 3.1 405B — Meta	NVIDIA H100 de 80 GB	Meta no publicó el costo total del hardware	39.3 millones de horas-GPU	Las GPUs H100 pueden alcanzar hasta 700 W por unidad	No divulgado oficialmente
DeepSeek-V3 — DeepSeek	NVIDIA H800	Costo de cómputo estimado: US\$ 5.576 millones	2.788 millones de horas-GPU	No divulgado en watts totales	No divulgado oficialmente